



UNIVERSIDAD DE LOS LAGOS




Electivo III: Machine Learning

Problema de Overfitting

Joel S. Torres




Departamento de Ciencias de la Ingeniería
Ingeniería Civil Informática

MACHINE LEARNING



Overfitting


Volvamos un poco al modelo de regresión lineal



Si existen demasiados atributos, el modelo puede ajustarse excesivamente bien al conjunto de entrenamiento ($J(\theta) \approx 0$), pero falla al generalizar las predicciones a nuevos datos de entrada.


Overfitting

Si vemos el mismo fenómeno en clasificación




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

(g = sigmoid function)



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$$


Overfitting

Opciones para evitar este problema


- 1 Reducir el número de atributos
 - Seleccionar un conjunto manualmente
 - Utilizar un modelo de selección
- 2 Regularización
 - Mantiene los atributos, pero reduce la magnitud de los parámetros θ_j
 - Funciona bien con un conjunto de atributos, ya que cada atributo contribuye un poco a predecir la salida

Regularización

Regularizando la función de costo: Intuición



$$\theta_0 + \theta_1 x + \theta_2 x^2$$



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

Se penalizan los valores θ

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + 1000\theta_3^2 + 1000\theta_4^2$$

$$\theta_3 \approx 0, \theta_4 \approx 0$$

Regularización

¿Qué es Regularización? Se penalizan los valores $\theta_0, \dots, \theta_n$

- Es una hipótesis más simple
- Compensa el sobreajuste

Ejemplo: Boston Housing

- Atributos: x_1, \dots, x_m (Boston: 13 atributos)
- Parámetros: $\theta_0, \dots, \theta_n$

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

El simbolo λ es el parámetro de regularización

- Permite que el modelo se ajuste adecuadamente
- Minimiza los parámetros
- Es un valor de penalización (si es demasiado grande, entonces el modelo no se ajustará)

Regularización

Algorithm 1: Descenso de Gradiente

Result: Encuentra $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

repeat

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)};$$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) * x^{(i)} + \frac{\lambda}{m} \theta_j \right], j \in \{1, \dots, n\};$$

until *Converger*;

Regularización

Algorithm 2: Descenso de Gradiente

Result: Encuentra $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

repeat

$$\begin{aligned} \theta_0 &:= \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}; \\ \theta_j &:= \theta_j (1 - \alpha \frac{\lambda}{m}) - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) * x^{(i)}, j \in \{1, \dots, n\}; \end{aligned}$$

until *Converger*;

$$1 - \alpha \frac{\lambda}{m} < 1$$

Ecuación Normal

$$\theta = (X^T + \lambda L)^{-1} X^T y$$

donde,

$$L = \begin{bmatrix} 0 & & & \\ & 1 & & \\ & & 1 & \\ & & & \dots \\ & & & & 1 \end{bmatrix}$$

Siguiente Clase

- Redes Neuronales
- Aprendizaje No Supervisado