



UNIVERSIDAD DE LOS LAGOS




Electivo III: Machine Learning

Clasificación

Joel S. Torres

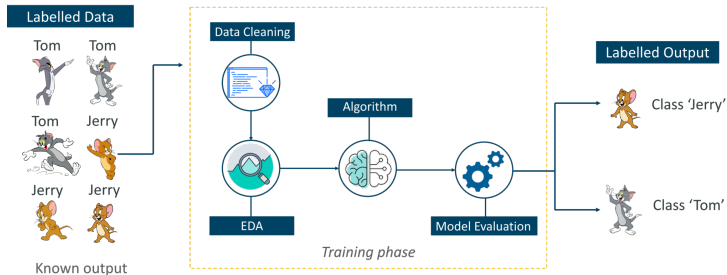
Departamento de Ciencias de la Ingeniería
Ingeniería Civil Informática

MACHINE LEARNING



Clasificación

¿Qué es la Clasificación?




$$y \in \{0, 1\}$$

- 0 Clase Negativa (Tom)
- 1 Clase Positiva (Jerry)

Clasificación

Predicción de tipo de Cancer (M,B)



¿Cómo representar el problema?


- 0 Tumor Benigno
- 1 Tumor Maligno

¿Qué método utilizar?

Intentemos una regresión lineal...

Clasificación

Predicción de tipo de Cancer (M,B)




Una pista: Utilizar un limitador (threshold)

Entonces para un threshold $T = 0,5$:

- $h_{\theta}(x) \geq T$, predice salida $y = 1$
- $h_{\theta}(x) < T$, predice salida $y = 0$

Clasificación

Predicción de tipo de Cancer (M,B)



Una pista: Utilizar un limitador (threshold)

Entonces para un limitador $L = 0,5$:

- $h_{\theta}(x) \geq L$, predice salida $y = 1$
- $h_{\theta}(x) < L$, predice salida $y = 0$

Logistic Regression

Objetivo del modelo


Se necesita restringir el modelo a $0 \leq h\theta(x) \leq 1$

Nuevo Modelo

$$h_{\theta}(x) = g(\theta^T x)$$

¿Qué es $g()$?

$$g(z) = \frac{1}{1 + e^{-z}}$$



Esta función se llama sigmoidea (sigmoid function) o función logística.


Logistic Regression

Entonces, con $z = \theta^T x$:

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Objetivo del modelo

Ajustar los parámetros θ con el menor costo posible.



Interpretación del resultado de la hipótesis

El modelo se basa en probabilidad

$h_{\theta}(x)$ = Estima la probabilidad de que $y = 1$ para la entrada x

Ejemplo

$$\text{Si } x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{MedidaTumor} \end{bmatrix}; y, h_{\theta}(x) = 0,7$$

Significa que hay una chance del 70 % de que el tumor sea **maligno**

Entonces,

$$h_{\theta}(x) = P(y = 1|x; \theta)$$

“la probabilidad de que $y = 1$, dado un x parametrizado por θ ”

Algunas Propiedades:


- $P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$
- $P(y = 0|x; \theta) = 1 - P(y = 1|x; \theta)$

Límites de Decisión

El impacto de los límites

Para predecir $y = 1$ debemos definir un limitador $h_{\theta}(x) \geq 0,5$

Por lo tanto, $y = 0$ debe tener un limitador $h_{\theta}(x) < 0,5$



Si, $g(z) \geq 0,5$ cuando $z \geq 0$

Entonces,


$$h_{\theta}(x) = g(\theta^T x) \geq 0,5$$

cuando,

$$\theta^T x \geq 0$$

Límites de Decisión

Ejemplo



Asimilando lo anterior,

Si, $h_{\theta}(x) = g(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2)$

Considerando un vector $\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$

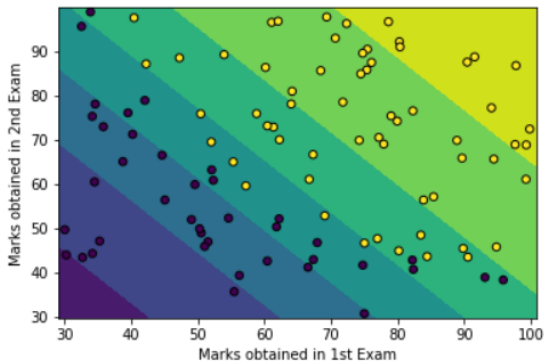
Para predecir $y = 1$ tendremos que comprobar que $-3 + x_1 + x_2 \geq 0$

Lo que implica que, $x_1 + x_2 \geq 3$

Límites de Decisión


Definición

Un límite de decisión es una línea que representa la separación entre la probabilidad de pertenecer a alguna de las categorías propuestas




Límites de Decisión No Lineales

¿Cómo solucionar este problema?



Límites de Decisión No Lineales



Nueva hipótesis,


$$h_{\theta}(x) = g(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2 + \theta_3 * x_1^2 + \theta_4 * x_2^2)$$

Considerando un vector $\theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$

Para predecir $y = 1$ tendremos que comprobar que $-1 + x_1^2 + x_2^2 \geq 0$
Lo que implica que, $x_1^2 + x_2^2 \geq 1$

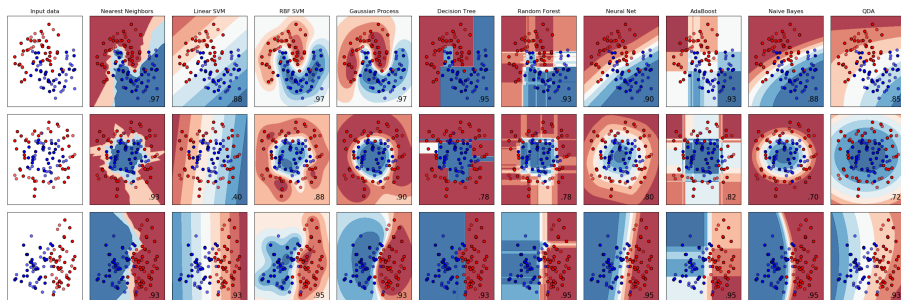
Límites de Decisión No Lineales

¿Cómo implementar otras figuras?



Hipótesis General

$$h_{\theta}(x) = g(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2 + \theta_3 * x_1^2 + \theta_4 * x_1^2 x_2 + \theta_5 * x_1^2 x_2^2 + \theta_6 * x_1^3 x_2 + \dots)$$



Taller de Clasificación


Próxima Clase:

- Revisaremos la Función de costo y sus consecuencias
- Implementación en código
- Google Colab : <https://colab.research.google.com/>
- R Studio Cloud : <https://rstudio.cloud/>

Función de Costo

Probando con Función de costo anterior:



$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2, \text{ con } h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}} \text{ (Sigmoid)}$$



Función de Costo

Nueva Función de costo: $J(\theta) = \frac{1}{m} \sum_{i=1}^m (Cost(h_{\theta}(x), y))$


$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & , \text{ si } y = 1 \\ -\log(1 - h_{\theta}(x)) & , \text{ si } y = 0 \end{cases}$$



Función de Costo

Nueva Función de costo: $J(\theta) = \frac{1}{m} \sum_{i=1}^m (Cost(h_{\theta}(x), y))$

$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & , \text{ si } y = 1 \\ -\log(1 - h_{\theta}(x)) & , \text{ si } y = 0 \end{cases}$$



Funcionamiento del Costo

- Si $h_{\theta}(x) = 1$, entonces $Cost(h_{\theta}(x), y) = 0$
- Si $h_{\theta}(x) = 0$, entonces $Cost(h_{\theta}(x), y) = \infty$


Intuición

Si $h_{\theta}(x) = 0$ predice que $P(y = 1|x; \theta) = 0$, cuando debería ser $y = 1$, entonces se PENALIZA con un alto costo.

Función de Costo

Nueva Función de costo: $J(\theta) = \frac{1}{m} \sum_{i=1}^m (Cost(h_{\theta}(x), y))$

$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & , \text{ si } y = 1 \\ -\log(1 - h_{\theta}(x)) & , \text{ si } y = 0 \end{cases}$$



Funcionamiento del Costo

- Si $h_{\theta}(x) = 0$, entonces $Cost(h_{\theta}(x), y) = 0$
- Si $h_{\theta}(x) = 1$, entonces $Cost(h_{\theta}(x), y) = \infty$

Intuición

Si $h_{\theta}(x) = 1$ predice que $P(y = 0|x; \theta) = 1$, cuando debería ser $y = 0$, entonces se PENALIZA con un alto costo.

Función de Costo

Nueva Función de costo considerando todos los atributos entrada:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m (\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}))$$

Se puede reescribir como:

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = -y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))$$

Entonces la Función de Costo para Regresión Lineal es:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})))$$

El objetivo es Minimizar el costo:

$$\min_{\theta} J(\theta)$$

Algoritmo Descenso del Gradiente

Algorithm 1: Descenso de Gradiente

Result: Encuentra $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

repeat

for $j \leftarrow 0$ **to** m **do**

$\theta_j := \theta_j - \alpha \frac{d}{d\theta_j} J(\theta);$

end

until *Converger*;

Algoritmo Descenso del Gradiente

Algorithm 2: Descenso de Gradiente

Result: Encuentra $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

repeat

for $j \leftarrow 0$ **to** n **do**

$\theta_j := \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) * x_j^{(i)};$

end

until *Converger*;

Otros Algoritmos de Aprendizaje

- Gradiente Conjugado
- BFGS
- L-BFGS

Ventajas:

- No es necesario fijar el α .
- Más rápidos que el Descenso de Gradiente.

Desventaja:

- Mucho más complicados de implementar.


Clasificación Multiclase

¿Y si ahora queremos identificar más clases?




Clasificación Multiclase

Binary classification:





Multi-class classification:





Clasificación Multiclase




Clasificación One vs All con Regresión Logística



Class 1: 


Class 2: 

Class 3: 




Clasificación One vs All con Regresión Logística

Binary classification:



Multi-class classification:



Taller de Clasificación

- Google Colab : <https://colab.research.google.com/>
- R Studio Cloud : <https://rstudio.cloud/>